

Técnicas de Aprendizagem Automática para Previsão da Capacidade de PTDs





TABLE OF CONTENTS

01

**ANÁLISE DOS
DADOS**

02

REGRESSÃO

03

CLASSIFICAÇÃO


04

DEMONSTRAÇÃO

05


CONCLUSÃO

Objectivos do trabalho



Regressão


Estimação da variável dependente contínua "Folga da Rede", prevendo assim a capacidade restante da rede com base em parâmetros relevantes.



Classificação

Previsão do nível de utilização da rede (baixa, média ou alta), consequentemente encontrado locais aptos para expansão da rede de estações de carregamento de VEs.

Modelos utilizados





01

ANÁLISE EXPLORATÓRIA DOS DADOS

Análise Exploratória

LED_Ratio


maioria dos PTDs já com níveis elevados de LED, mas ainda há margem de melhoria

Util_Decimal

rede em média subcarregada (concentração entre 0.2 e 0.6)

Cap_PTD_kVA

é o preditor mais correlacionado com a folga de potência





Variáveis e correlação

Variáveis-Alvo

PFolga_PTD
Ganho_LED_PTD
D_PTD
Rate_Ineficiencia
PVE_PTD
utilizRede

Variáveis de input

Potência instalada [kVA]	N_Luminarias
N_Clientes	N_Lampadas
P_IP_Total	Cap_per_Cliente
P_IP_Inef	Distrito_enc
LED_Ratio	Concelho_enc





02

REGRESSÃO

Resultados da regressão

Linear

MAE: **37.45**

RSME: **57.3**

Árvore

MAE: **36.3**

RSME: **58.7**

Linear SVR

MAE: **36.7**

RSME: **59.4**

Rede Neuronal

MAE: **35.4**

RSME: **55.4**




Legenda:

MAE (Erro absoluto médio) **RSME** (Raíz do erro quadrático médio)

Validação da Regressão

NeuralNet: Treino adequado curvas convergem e gap reduzido

Árvore: Treino adequado curvas convergem e gap reduzido



Melhor modelo: Rede neuronal

A diferença é estatisticamente significativa ($p=0.0141 < 0.05$).

The background features a white field with abstract geometric elements. On the left, there are grey chevron-like shapes and a red line that zig-zags downwards. A semi-transparent grey circle with a fine dot pattern is positioned in the upper left. Several thin red lines are scattered across the top and right areas.

03

CLASSIFICAÇÃO

Resultados da classificação

KNN

Accuracy: 0.64

F1: **0.63**

Linear SVC

Accuracy: 0.6

F1: **0.52**

Árvore

Accuracy: 0.65

F1: **0.64**

Rede Neuronal

Accuracy: 0.66

F1: **0.65**

Métricas por classe (Rede neuronal)

Alto

Precision: 0.7

F1: 0.6

Médio

Precision: 0.67

F1: 0.72

Baixo

Precision: 0.54

F1: 0.5

Métricas por classe (Árvore)

Alto

Precision: 0.68

F1: 0.58

Médio


Precision: 0.67

F1: 0.6

Baixo

Precision: 0.68


F1: 0.58



Validação da Classificação



NeuralNet: Treino adequado

Árvore: Treino adequado



Matriz de confusão


Matriz de Confusão - Rede Neuronal (Profunda (3 camadas, L2 forte))



Melhor modelo: Rede neuronal

A diferença é estatisticamente significativa ($p=0.0141 < 0.05$).

Curvas de Aprendizagem — Comparação entre Perfis



Perfis de treino


Trade-off entre velocidade de treino e precisão dos modelos



04




DEMONSTRAÇÃO

The background features a white field with abstract geometric elements. On the left, there are grey chevron-like shapes and a red line that zig-zags downwards. A semi-transparent grey circle with a fine dot pattern is positioned in the upper left. Several thin red lines are scattered across the top and right areas.

05


CONCLUSÃO

Conclusões



Desenvolvimentos Futuros

As principais limitações do estudo são: a falta de dados temporais (o que impede prever picos de consumo); o facto de as variáveis geográficas estarem agregadas por concelho, introduzindo ruído; a exclusão da potência contratada devido a muitos valores omissos; o baixo desempenho na classificação da classe "baixo" ($F1 \approx 0,50$); e o uso de estimativas teóricas para a carga dos veículos elétricos. Possíveis melhorias futuras incluem a introdução de séries horárias, a resolução dos dados omissos da potência contratada, o uso de modelos ensemble, o reequilíbrio das classes e a validação com dados reais de carregamento de VEs.



No Âmbito do Projeto

Os modelos desenvolvidos são uma ferramenta promissora para triagem e diagnóstico do estado da rede em diversas localizações, com grande potencial no seu uso para descobrir que locais poderiam mais facilmente alojar uma expansão da rede de estações de carregamento de veículos elétricos.



Obrigado!

Alguma pergunta?

Rui Santiago 1221402@isep.ipp.pt

Rui Silva 1231105@isep.ipp.pt

Tiago Barros 1231108@isep.ipp.pt

CREDITS: This presentation template was created by **Slidesgo**, and includes icons by **Flaticon**, and infographics & images by **Freepik**